

2. Масштабирование признаков. Регуляризация.

Стохастический градиентный спуск.

```
import numpy as np
import matplotlib.pyplot as plt
```

```
# К признаку стажа добавим новые признаки
X = np.array([[1, 1, 1, 1, 1, 1, 1, 1, 1, 1],
              [1, 1, 2, 1, 3, 0, 5, 10, 1, 2], # стаж
              [500, 700, 750, 600, 1450,
               800, 1500, 2000, 450, 1000], # средняя стоимость занятия
              [1, 1, 2, 1, 2, 1, 3, 3, 1, 2]]) # квалификация репетитора

y = [45, 55, 50, 59, 65, 35, 75, 80, 50, 60]
```

Нормализация [0, 1]

$$x_{ij} = \frac{x_{ij} - \min_j(x_{ij})}{\max_j(x_{ij}) - \min_j(x_{ij})}$$

Стандартизация

$$x_{ij} = \frac{x_{ij} - \mu_j}{\sigma_j}$$

```
X_st = X.copy().astype(np.float64)
```

Сохранено



```
X[1].std()
```

```
array([-0.57142857, -0.57142857, -0.21428571, -0.57142857,  0.14285714,
       -0.92857143,  0.85714286,  2.64285714, -0.57142857, -0.21428571])
```

```
def calc_std_feat(x):
    res = (x - x.mean()) / x.std()
    return res
```

```
X_st[2] = calc_std_feat(X[2])
X_st[3] = calc_std_feat(X[3])
print(X_st[2])
print(X_st[3])
```

```
[-0.97958969 -0.56713087 -0.46401617 -0.77336028  0.97958969 -0.36090146
```

```

1.08270439  2.11385144 -1.08270439  0.05155735]
[-0.89625816 -0.89625816  0.38411064 -0.89625816  0.38411064 -0.89625816
 1.66447944  1.66447944 -0.89625816  0.38411064]

```

```
### L1 регуляризация - Lasso
```

$$\sum_{i=1}^n L_i(\vec{x}_i, y_i, \vec{w}) + \lambda \sum_{j=1}^m |w_j| \rightarrow \min_w$$

```
### L2 регуляризация - Ridge
```

$$\sum_{i=1}^n L_i(\vec{x}_i, y_i, \vec{w}) + \lambda \sum_{j=1}^m w_j^2 \rightarrow \min_w$$

```

def calc_mse(y, y_pred):
    err = np.mean((y - y_pred)**2)
    return err
def eval_model_reg2(X, y, iterations, alpha=1e-4, lambda_=1e-8):
    np.random.seed(42)
    W = np.random.randn(X.shape[0])
    n = X.shape[1]
    for i in range(1, iterations + 1):
        y_pred = np.dot(W, X)
        err = calc_mse(y, y_pred)
        W -= alpha * (1/n * 2 * np.dot((y_pred - y), X.T) + 2 * lambda_ * W)

    return W

```

▼ Домашние задания

1. Постройте график зависимости весов всех признаков от lambda в L2-

Сохранено (ошибка).

```

def build_mse_plots(lambdas, model):
    %matplotlib widget
    for l in lambdas:
        W = model(X_st, y, iterations=10000, alpha=1e-2, lambda_=l)
        plt.plot(range(len(W)), W, label=f'\lambda = {l}')
        plt.legend()
    plt.xlabel('Iteration number')
    plt.ylabel('Weights');

```

```
lambdas = [-10e-3, 10e-5, 10e-2, 1, 10]
```

```
build_mse_plots(lambdas, eval_model_reg2)
```

2. Можно ли к одному и тому же признаку применить сразу и нормализацию, и стандартизацию?

Можно, но зачем? Нормализация и стандартизация делают разные вещи: нормализация преобразует данные в диапазоне $[0, 1]$, стандартизация преобразует данные так, что полученное распределение имело среднее $=0$ и стандартное отклонение $=1$, то есть данные методики минимизации взаимозаменяемы и взаимоисключаемы.

3. *Напишите функцию наподобие eval_model_reg2, но для применения L1-регуляризации.

```
def eval_model_reg1(X, y, iterations, alpha=1e-4, lambda_=1e-8):
    np.random.seed(42)
    W = np.random.randn(X.shape[0])
    n = X.shape[1]
    for i in range(1, iterations + 1):
        y_pred = np.dot(W, X)
        err = calc_mse(y, y_pred)
        # невозможно определить направление градиента,
        # поэтому вместо abs(W) возьмём знак по W
        W -= alpha * (1/n * 2 * np.dot((y_pred - y), X.T) + lambda_ * np.sign(W))

    return W
```

```
lambdas = [-2, 10e-1, 2, 10]
build_mse_plots(lambdas, eval_model_reg1)
```

Сохранено



Сохранено

